

รายงานสรุปผลการทดลอง LAB-04

Machine Learning Classification & Clustering (FPL Dataset)

1. วัตถุประสงค์และภาพรวมการทดลอง

การทดลองนี้มีวัตถุประสงค์เพื่อประยุกต์ใช้อัลกอริทึม **k-Nearest Neighbors (KNN)** ในการจำแนกประเภท (Classification) และ **K-Means Clustering** ในการจัดกลุ่มสโมสรฟุตบอล (Clustering) บนชุดข้อมูลสถิตินักเตะ **Fantasy Premier League (FPL)** โดยเน้นการเปรียบเทียบประสิทธิภาพของโมเดล ณ ค่า k ที่แตกต่างกัน และวิเคราะห์ขอบเขตพฤติกรรมข้อมูลของผู้เล่นตามสถิติการเล่นจริง

2. ข้อมูลและการเตรียมประมวลผล (Dataset & Preprocessing)

สรุปข้อมูลหลัก

- ชุดข้อมูล:** fpl.csv (จำนวนผู้เล่นทั้งหมด 567 คน)
- การกรองข้อมูล (Data Cleaning):** คัดเลือกเฉพาะผู้เล่นที่มีเวลาลงสนาม (minutes) ≥ 180 นาที เพื่อตัดข้อผิดพลาดจากผู้เล่นสำรองที่ไม่มีสถิติ ส่งผลให้เหลือข้อมูลคุณภาพจำนวน **340 คน**
- การแบ่งสัดส่วนชุดข้อมูล:** แบ่งชุดฝึกฝน (Train set 70% = 238 คน) และชุดทดสอบ (Test set 30% = 102 คน) ด้วยวิธี Stratified Sampling
- การทำให้ข้อมูลมาตรฐาน (Feature Scaling):** ใช้ StandardScaler ปรับข้อมูล 14 คุณลักษณะ (เช่น goals_scored, assists, tackles, recoveries, ict_index) ให้อยู่ในรูป Z-score ($\mu = 0, \sigma = 1$) เพื่อป้องกันไม่ให้ฟีเจอร์ที่มีสเกลใหญ่ข่มระยะทางในการคำนวณ Euclidean Distance

สัดส่วนตำแหน่งนักเตะในชุดข้อมูล (Target Classes)

MID (กองกลาง): 155 คน (45.6%)	DEF (กองหลัง): 118 คน (34.7%)	FWD (กองหน้า): 39 คน (11.5%)	GKP (ผู้รักษาประตู): 28 คน (8.2%)
----------------------------------	----------------------------------	---------------------------------	--------------------------------------

3. สรุปผลการทดลองการจำแนกประเภท (KNN Classification)


ตารางเปรียบเทียบประสิทธิภาพตามค่า k (Test Set = 102 คน)

ค่า k (n_neighbors)	Test Accuracy Score	Accuracy (%)	จำนวนคนที่ทายถูกต้อง	จำนวนคนที่ทายผิด
$k = 3$	0.8725	87.25%	89 / 102	13 คน
$k = 5$	0.8529	85.29%	87 / 102	15 คน
$k = 7$ (Best)	0.9020	90.20%	92 / 102	10 คน
$k = 9$	0.8725	87.25%	89 / 102	13 คน

✓ ผลลัพธ์ที่ดีที่สุด: โมเดล ณ $k = 7$ ให้ความถูกต้องสูงสุดที่ 90.20% (ทำนายถูกต้อง 92 จาก 102 คน)

รายละเอียดการประเมินผลแยกตามตำแหน่ง (Classification Report at $k = 7$)

ตำแหน่ง (Position)	Precision	Recall	F1-Score	จำนวนทดสอบ (Support)
GKP (ผู้รักษาประตู)	1.00	1.00	1.00	8
DEF (กองหลัง)	0.87	0.94	0.90	35
MID (กองกลาง)	0.91	0.87	0.89	47
FWD (กองหน้า)	0.91	0.83	0.87	12
ค่าเฉลี่ยภาพรวม (Accuracy)	-	-	0.90	102





Confusion Matrix (k = 7)

	GKP	DEF	MID	FWD
GKP	8	0	0	0
DEF	0	33	2	0
MID	0	5	41	1
FWD	0	0	2	10
	GKP	DEF	MID	FWD

Predicted Label

4. สรุปผลการจัดกลุ่ม (K-Means Clustering)

- **การหาจำนวนกลุ่มที่เหมาะสม (Elbow Method):** ค่า Inertia (Within-Cluster Sum of Squares) ลดลงอย่างต่อเนื่องและเกิดจุดหักเหที่เด่นชัด ณ $K = 4$ ซึ่งสอดคล้องกับตำแหน่งหลักทั้ง 4 ในกีฬาฟุตบอล
- **การลดมิติข้อมูลเพื่อแสดงผล (PCA Visualization):** เมื่อฉายข้อมูล 14 มิติลงบนพื้นที่ 2 มิติผ่าน Principal Component Analysis (PCA) พบว่า:
 - กลุ่มผู้รักษาประตู (GKP) แยกตัวออกจากกลุ่มอื่นอย่างเด็ดขาด
 - กลุ่มกองหลัง (DEF) และกองกลาง (MID) มีพื้นที่ทับซ้อนกันบางส่วน เนื่องจากสถิติการตัดบอลและการทำเกมของกองหลังวิงแบ็คและกองกลางตัวรับมีความใกล้เคียงกัน



5. อภิปรายและสรุปผลการทดลอง (Discussion & Conclusion)

- **อิทธิพลของค่า k ใน KNN:**
 - ค่า k ที่น้อยเกินไป ($k = 3, 5$) ทำให้โมเดลไวต่อ Noise หรือผู้เล่นที่มีสถิติสุดโต่งเฉพาะบุคคล
 - ค่า $k = 7$ เป็นระดับที่สร้างขอบเขตการตัดสินใจ (Decision Boundary) ได้เรียบและสมดุลที่สุด ส่งผลให้ได้ค่าความถูกต้องสูงสุด 90.20%
- **คุณลักษณะของฟีเจอร์เฉพาะตำแหน่ง:**
 - สถิติเฉพาะทาง เช่น saves ช่วยให้ง่ายแก่การจำแนกผู้รักษาประตูได้ถูกต้อง 100%
 - ความผิดพลาดส่วนใหญ่เกิดขึ้นระหว่าง DEF และ MID เนื่องจากการเปลี่ยนผ่านบทบาทในฟุตบอลสมัยใหม่ที่กองหลังมีส่วนร่วมกับการเกมรุก และกองกลางมีบทบาทเกมรับมากขึ้น
- **การจัดโครงสร้างโปรเจกต์และการเวอร์ชันซอฟต์แวร์:**
 - การแยกโมดูล classification และ clustering ออกเป็นโครงสร้างระบบระเบียบ ช่วยให้ง่ายต่อการซ่อมบำรุงและรับประมวลผลซ้ำผ่านระบบติดตามเวอร์ชัน Git/GitHub