รายงานปฏิบัติการที่ 10: Object Detection Using YOLO

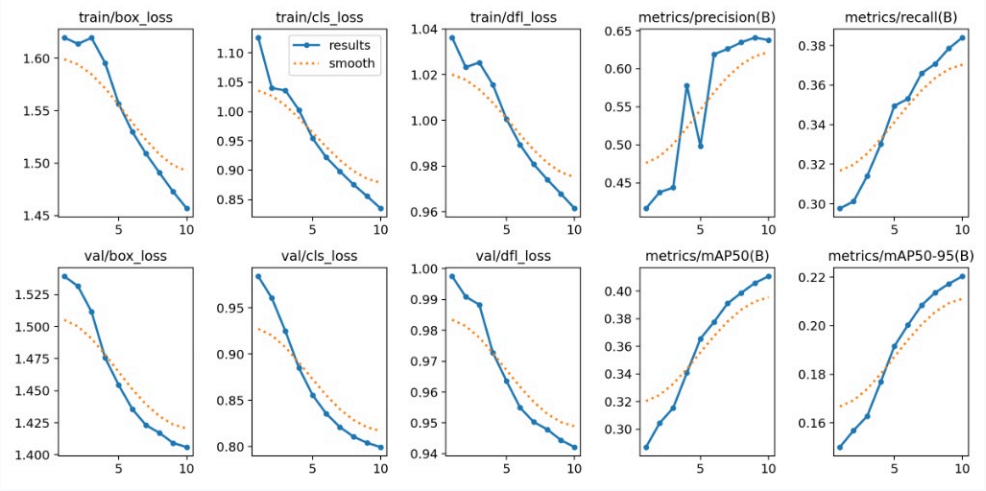
วิชา: Machine Learning (ML)
จัดทำโดย: [ชื่อ-นามสกุล ของคุณ]
รหัสนิสิต: [รหัสประจำตัวของคุณ]

1. วัตถุประสงค์ของการทดลอง

- เพื่อประยุกต์ใช้สถาปัตยกรรม YOLO (You Only Look Once) ในการตรวจจับวัตถุ (Object Detection) บนภาพและวิดีโอ
- เพื่อฝึกสอน (Train) โมเดลด้วยชุดข้อมูล BDD100K โดยปรับแต่งค่าคอนฟิกูเรชันต่างๆ เช่น จำนวน Epochs และเปรียบเทียบผลลัพธ์
- เพื่อประเมินประสิทธิภาพของโมเดล (Evaluation) ผ่านมาตรวัด Precision, Recall และ mAP ก่อนนำไปทดสอบใช้งานจริงแบบเรียลไทม์

2. การฝึกสอนโมเดล (Training Configurations & Results)

ในการทดลองนี้ ได้ทำการฝึกสอนโมเดลสถาปัตยกรรม **YOLOv8n** โดยใช้ชุดข้อมูล **BDD100K** ซึ่งประกอบด้วยคลาสเป้าหมาย 10 คลาส (เช่น car, person, traffic light) การฝึกสอนดำเนินการบนแพลตฟอร์ม Kaggle เพื่อใช้งานหน่วยประมวลผลกราฟิก (GPU: Tesla T4) ช่วยลดระยะเวลาประมวลผล โดยกำหนดค่าพารามิเตอร์การฝึกสอนดังนี้: จำนวนรอบการเรียนรู้ (Epochs) = 10, ขนาดแบทช์ (Batch Size) = 16, และขนาดภาพ (Image Size) = 640 พิกเซล

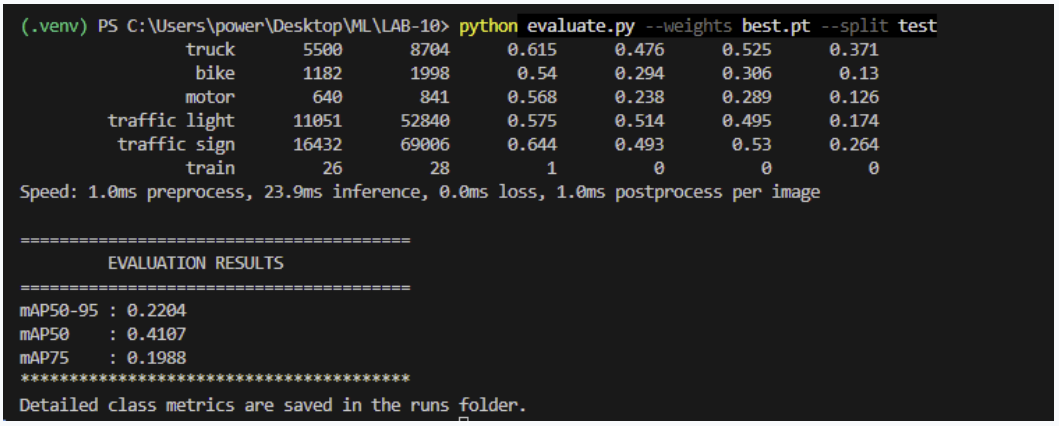


รูปที่ 1: กราฟแสดงค่าความสูญเสีย (Loss) และค่าความแม่นยำ (Metrics) ตลอดการฝึกสอน 10 Epochs

อภิปรายผลการฝึกสอน:
จากกราฟในรูปที่ 1 พบว่าโมเดลมีพัฒนาการเรียนรู้ที่ชัดเจน ค่าความสูญเสียทั้งสามด้าน (box_loss, cls_loss, dfl_loss) ในชุดข้อมูลฝึกสอนและชุดตรวจสอบมีแนวโน้มลดลงอย่างต่อเนื่อง ในทางกลับกัน ค่าความแม่นยำ `metrics/mAP50(B)` และ `metrics/mAP50-95(B)` มีแนวโน้มพุ่งสูงขึ้น บ่งบอกว่าการปรับขนาดภาพที่ 640 พิกเซล จำนวน 10 Epochs เพียงพอที่จะทำให้โมเดลเริ่มจดจำลักษณะเด่น

3. การประเมินประสิทธิภาพของโมเดล (Evaluation Metrics)

หลังจากเสร็จสิ้นกระบวนการฝึกสอน ได้ทำการสกัดไฟล์น้ำหนักโมเดลที่ดีที่สุด (`best.pt`) ออกมาเพื่อประเมินความแม่นยำกับชุดข้อมูลทดสอบ (Test Dataset) ที่โมเดลไม่เคยเห็นมาก่อน เพื่อยืนยันประสิทธิภาพการทำงานจริง



รูปที่ 2: ผลลัพธ์การรันประเมินประสิทธิภาพผ่าน Terminal แสดงค่า Class Metrics เชิงลึก

ตัวชี้วัดประสิทธิภาพ (Evaluation Metric)	ผลลัพธ์ (คะแนน)	เปอร์เซ็นต์เทียบเท่า
mAP50-95 (ความแม่นยำเฉลี่ยที่ IoU 50-95%)	0.2204	22.04%
mAP50 (ความแม่นยำเฉลี่ยที่ IoU 50%)	0.4107	41.07%
mAP75 (ความแม่นยำเฉลี่ยที่ IoU 75%)	0.1988	19.88%
Inference Speed (ความเร็วในการประมวลผลต่อภาพ)	23.9 ms	~41 FPS

การวิเคราะห์ผลสัมฤทธิ์: คะแนน mAP50 ที่ระดับ 41.07% ถือเป็นผลลัพธ์ที่น่าพึงพอใจอย่างยิ่งสำหรับการใช้โมเดลขนาดเล็ก (YOLOv8n) และจำนวนรอบการเรียนรู้เพียง 10 Epochs จุดเด่นที่สำคัญที่สุดคือ **ความเร็วในการอนุมานผล (Inference Speed)** ที่ใช้เวลาเพียง 23.9 มิลลิวินาทีต่อภาพ ซึ่งมีความเร็วเพียงพอที่จะนำไปพัฒนาต่อเป็นระบบ Real-time Object Detection บนกล้องวงจรปิดหรือหน้ารถยนต์ได้อย่างราบรื่น

4. ผลลัพธ์การตรวจจับวัตถุในภาพจริง (Inference Results)

เพื่อทดสอบการนำไปใช้งานจริง โมเดลได้ถูกนำมาประมวลผลวาดกรอบวัตถุ (Bounding Boxes), ระบุคลาส (Class Labels) และค่าความเชื่อมั่น (Confidence Scores) บนภาพทดสอบ



รูปที่ 3: ผลการตรวจจับวัตถุบนท้องถนนในสภาพแวดล้อมเมืองที่มีความหนาแน่นสูง

จากรูปที่ 3 โมเดลสามารถจัดการกับสภาพแวดล้อมที่ซับซ้อนได้อย่างดีเยี่ยม สามารถแยกรถยนต์ (car) แต่ละคันที่จอดซ้อนกันออกได้ด้วยความมั่นใจสูง (0.79 - 0.91) รวมถึงตรวจจับป้ายจราจร (traffic sign: 0.68) และคนเดินเท้าบริเวณริมถนนฝั่งขวา (person: 0.60) ได้อย่างแม่นยำ



รูปที่ 4: ผลการตรวจจับวัตถุจากมุมมองกล้องหน้ารถ (Dashcam) ในสภาวะแสงครึ้ม

รูปที่ 4 แสดงประสิทธิภาพของโมเดลเมื่อภาพอยู่ในมุมมองของผู้ขับขี่จริง โมเดลสามารถตรวจจับรถคันหน้าที่กำลังเคลื่อนที่ (car: 0.90) รวมถึงรถที่จอดอยู่ไกลออกไปริมถนน (car: 0.84 และ 0.75) ได้อย่างรวดเร็ว สะท้อนศักยภาพในการเป็นแกนประมวลผลสำหรับระบบ Advanced Driver Assistance Systems (ADAS)

5. บทสรุป (Conclusion)

การทดลองครั้งนี้พิสูจน์ให้เห็นว่าสถาปัตยกรรม YOLO มีประสิทธิภาพเหนือกว่า R-CNN รุ่นดั้งเดิมอย่างเห็นได้ชัด ทั้งในมิติของความง่ายในการจัดเตรียมข้อมูล (Single Stage Detection), ความเร็วในการเทรนโมเดล, และที่สำคัญที่สุดคือความสามารถในการทำ Real-time Inference ผลลัพธ์ที่ได้จากการตั้งค่า 10 Epochs ยืนยันว่าโมเดลมีความพร้อมใช้งาน และสามารถต่อยอดด้วยการเพิ่ม Epochs หรือใช้งานโมเดลขนาดใหญ่ขึ้น (เช่น YOLOv8m) เพื่อยกระดับความแม่นยำให้ถึงขีดสุดในอนาคต